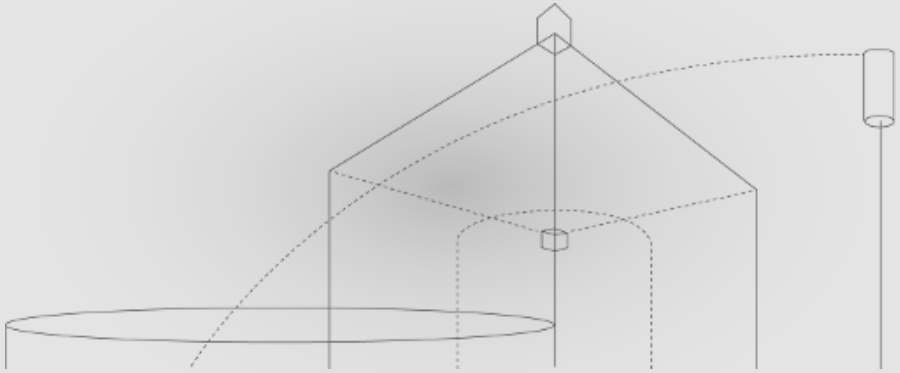
UTEC Posgrado

CAPSTONE PROJECT I · E5

Evaluación del modelo: plan, baseline, Model Card y riesgos



Equipo N.º 7 · Proyecto: Portal Gamarrino AI

Integrantes: Christian Cajusol, Hugo Ángeles, Francisco Meza, Jhomar Yurivilca ·

UTEC Posgrado

Cómo usar esta plantilla

Estructura común para todos los equipos; el contenido, las métricas y los métodos los eligen y justifican ustedes

1 **Plan de evaluación**
Las 6 preguntas del taller de la Semana 6 · *Evidencias 2.4 y 2.5 del P4*

2 **Baseline contra modelo v0**
Tabla comparativa con rangos y dónde falla el modelo · *Evidencias 2.3, 2.6, 2.7 y 4.2*

3 **Model Card v0**
Qué es el modelo, para qué sirve y para qué no · *Evidencia 5.3*

4 **Registro de 3 riesgos**
El registro del pre-mortem, completo · *Evidencia 5.4*

Reglas

- Cada caja trae pistas en gris: una para ML clásico y otra para LLM o agente. Usen la que corresponda y bórrenlas antes de entregar.
- Si algo no aplica a su proyecto, escriban «No aplica, porque…» en una línea. No fuercen contenido.
- Los números se reportan con su rango, no solos.
- Entrega por Canvas: este archivo en PDF más el enlace al notebook o repositorio.

Plan de evaluación (1/2)

1 · Problema de Agente

- Recuperación semántica + ranking top-3 (no es clasificación ni generación pura). El LLM solo redactaría la explicación breve de cada coincidencia; no decide qué tiendas se muestran.
- Unidad: consulta del usuario × catálogo de tiendas activas.
- Momento: al enviar la consulta en el asistente web móvil, antes de salir de casa (81,4%) o durante el viaje.
- Horizonte: inmediato, una sola interacción.
- Contexto: texto libre + memoria de sesión + catálogo activo (rag_text).

2 · Métrica ↔ KPI

- Métrica principal: Hit Rate@3, meta pre-registrada ≥70%.
- KPI de impacto: Tasa de recomendación útil ≥70% (informe preliminar).
- Contrapeso: latencia promedio ≤6s, p95 ≤10-12s.
- Compuesta (LLM/agente): calidad por etiquetado humano (κ=0,627, bajo el umbral de 0,80 que exige la rúbrica); LLM juez intentado y descartado (κ=0,515, no validó); costo <$0,01 USD por esta prueba; latencia por medir (sin prototipo desplegado aún).

3 · Baselines

1. No hacer nada: 3 tiendas al azar.
2. Lo que se hace hoy: filtro por categoría (como Gamarra.com.pe / Mi Gamarra), sin NLP.
3. Modelo simple: TF-IDF/léxico sobre rag_text.
4. Modelo v0: embeddings text-embedding-3-small + similitud de coseno (ChromaDB pendiente para escalar).

Plan de evaluación (2/2)

4 · Con qué datos se prueba

- Catálogo: 438 de 1.853 tiendas (consolidado operativo).
- Consultas: muestra sistemática con arranque al azar (semilla 42) de 378 (280 textos distintos, ponderados por frecuencia real), tomadas de 4.000 consultas reales en mano (de 21.186 históricas).
- Ninguna consulta de prueba se usó para ajustar el modelo. Es una muestra piloto, no el universo completo.

5 · Un rango y dónde falla

- Rango: IC 95% por bootstrap (1.000 remuestreos) sobre las 378 consultas ponderadas.
- 3 segmentos (ver Sección 2): específica de una prenda (240 casos ponderados), ambigua o compuesta (113), con marca/talla/precio explícito (25).

6 · Criterio de decisión

- Si el Hit Rate@3 de modelo v0 no supera a los baselines por más que el rango (intervalos se cruzan) → revisar embeddings/ranking antes del 21-nov.
- Resultado real: SÍ superó a los baselines (intervalos no se cruzan); NO alcanzó la meta pre-registrada de 70% (66,9% < 70%). Decisión: filtro híbrido (metadata + embeddings) para marca/talla/precio, y revisión del segmento ambiguo, antes del prototipo del 21-nov.
- Si el costo o la latencia real del prototipo supera 6s prom. / 10-12s p95 → simplificar pipeline o cambiar proveedor.

Baseline contra modelo v0

Una fila por opción. La métrica principal es la misma del plan, medida en el conjunto de prueba

Opción	Métrica principal: Hit Rate@3 (con rango)	Métrica de contrapeso: Latencia	Costo y latencia por caso*	N.º de casos de prueba
No hacer nada	23,0% [18,8-27,5]	—	$0	378 (280 dist.)
Lo que se hace hoy	46,8% [41,8-51,6]	Por medir	$0 / <50ms cómputo	378 (280 dist.)
Modelo simple	52,9% [48,2-57,7]	Por medir	$0 / <50ms cómputo	378 (280 dist.)
Modelo v0	66,9% [61,9-71,4]	Por medir (sin prototipo)	<$0,01 / ~0,3-0,5s embed.	378 (280 dist.)

Lectura en tres líneas

De 46,8% con lo que se hace hoy (filtro por categoría) a 66,9% con el modelo v0 (ponderado, IC95% 61,9-71,4%). La diferencia es mayor que el rango de ambos — los intervalos no se cruzan, es una mejora real, no ruido.

Conclusión: se justifica construir el prototipo v0 con embeddings en vez de quedarse con el filtro simple.

** Obligatorio para LLM o agente; opcional para ML clásico.*

Dónde falla el modelo v0

Error por segmento: dónde funciona peor y por qué creen que pasa

Segmento	N.º de casos	Métrica principal	Diferencia frente al total	Por qué creemos que pasa
Total	378 (280)	66,9%	—	—
Específica (una prenda)	240 (150 sin ponderar)	79,6% [IC95 74,6-84,6]	+12,7 pp	Nombre de prenda claro → el embedding encuentra match directo
Ambigua o compuesta	113 (105 sin ponderar)	50,4% [IC95 41,6-60,2]	-16,5 pp	Sin prenda o estilo/tendencia sin etiqueta en catálogo (yk2, años 2000, 'de pinterest')
Con marca, talla o precio	25 (25 sin ponderar)	20,0% [IC95 4,0-36,0]	-46,9 pp	Embeddings no filtran atributos estructurados (talla, precio, réplica)

Qué harán con esto antes del 21 de noviembre

Nota: La 'diferencia frente al total' es un número puntual, sin intervalo propio; el segmento de marca/talla/precio es el más chico (n=25, IC95% de 4,0% a 36,0%) y se lee como indicio, no como conclusión firme. Declaramos el segmento de marca/talla/precio como limitación conocida del v0 (motor semántico, no estructurado) y diseñamos un filtro híbrido (metadata + embeddings) para el prototipo del 21-nov. El segmento ambiguo queda documentado en el Model Card; no se fuerza su corrección antes de la entrega.

Model Card v0 (1/2)

Versión reducida de Mitchell et al. (2019). Una página en total, repartida en dos láminas

¿Qué es?

Motor de recuperación semántica: embeddings text-embedding-3-small (OpenAI) sobre el catálogo (rag_text: categoría, subcategoría, tags, descripción, ubicación) + similitud de coseno para el top-3. No es un LLM generativo decidiendo — el LLM solo redactaría la explicación breve (pendiente de implementar). Versión v0, piloto.

Uso previsto

Comprador individual en Gamarra, en el asistente web móvil, para decidir qué tiendas visitar — antes de salir de casa o durante el recorrido. Responde consultas en lenguaje natural con un top-3 de tiendas del directorio.

Uso no previsto

- No garantiza stock, talla o precio en tiempo real. No procesa búsqueda por imagen.
- No debe usarse para validar autenticidad/legalidad de productos.
- No es apto para consultas con restricciones estrictas de talla/marca/precio.

Datos

- Catálogo de 438 tiendas de Portal Gamarrino (de 1.853 totales; ver datasheet E4).
- Prueba: muestra sistemática de 378 (280 distintas) de 4.000 consultas reales en mano (de 21.186 históricas), semilla 42.

Model Card v0 (2/2)

Resultados

- Hit Rate@3 = 66,9% [61,9-71,4%] (ponderado, 378 consultas), frente a 52,9% del léxico y 46,8% del filtro por categoría — mejora real, intervalos no se cruzan.
- Segmento más débil: marca/talla/precio explícito (20,0%, -46,9pp).

Cómo se evaluó

- Juicios binarios Sí/No etiquetados por los 4 integrantes, doble ciego + desempate con reglas escritas.
- LLM juez (Claude) intentado primero: κ=0,515, no validó.
- Humano-humano: acuerdo bruto 87,4% / κ=0,627 en consultas generales (reevaluación ciega real, 3 réplicas independientes); acuerdo 93-94% / κ=0,86-0,88 en los pares nuevos propuestos por modelo v0.

Limitaciones

- No filtra talla/precio/disponibilidad real (HR@3 cae a 20% ahí; filtro híbrido metadata+embeddings planificado para el prototipo del 21-nov). El acuerdo humano sobre 'relevante' tiene un techo real (87,4% bruto / κ≈0,63) en consultas ambiguas de estilo (yk2, años 2000, 'de pinterest') — el catálogo no tiene esas etiquetas.
- Evaluado sobre 438/1.853 tiendas y 378/21.186 consultas (piloto, no universo completo). Costo y latencia del prototipo real aún no medidos (sin despliegue).

Consideraciones éticas

- No se procesan datos personales de compradores (solo texto de consulta). Catálogo sin datos de contacto expuestos fuera de lo autorizado (H3, uso académico, firmado 6-oct-2026).
- Riesgo: consultas piden productos 'réplica' — el sistema no debe recomendar tiendas como fuente de falsificaciones (ver riesgo 3).
- Sesgo potencial: el ranking puede favorecer tiendas con fichas más completas — pendiente de monitoreo.

Registro de los 3 riesgos principales

El registro del pre-mortem, completo. Categorías: datos · modelo · adopción · ética o regulación (Se consideró también dependencia de la API de OpenAI y privacidad de las consultas; se priorizaron estos 3 por mayor probabilidad/impacto actual.)

#	Riesgo	Categoría	Prob.	Impacto	Mitigación	Señal de alerta	Responsable
1	Limitación del etiquetado: el acuerdo humano sobre relevancia tiene un techo real (87,4% bruto / κ≈0,63) en consultas ambiguas de estilo/tendencia.	Datos	Alta	Medio	Declarar la limitación en el Model Card; para Capstone II, enriquecer el catálogo con etiquetas de estilo y repetir el etiquetado con guía más detallada	Kappa de una nueva ronda de etiquetado por debajo de 0,80 (umbral de la rúbrica) al 21 de noviembre	Equipo completo
2	Los embeddings no filtran atributos estructurados (talla, precio, marca) — HR@3 cae a 20% en ese segmento, el más débil de los tres	Modelo	Alta	Alto	Diseñar un filtro híbrido (metadata estructurada + embeddings) para el prototipo del 21-nov; mientras tanto, declarar la limitación	Más del 30% de las quejas de usuarios de prueba son por talla/precio no filtrado, medido al 21 de noviembre	Equipo técnico
3	Consultas reales piden productos 'réplica' (ej. 'polos réplica a1') — recomendar tiendas sin verificar puede facilitar la venta de falsificaciones	Ética o regulación	Media	Alto	Decisión de producto: el agente RECHAZA la consulta (no busca ni recomienda ninguna tienda) cuando detecta intención de réplica/falsificación — ya no es solo una regla de evaluación. Confirmar el criterio de detección con el asesor antes del 21 de noviembre.	Consultas de réplica/marca no autorizada en más del 5% de una muestra ampliada, medido al 21 de noviembre.	Francisco Meza / asesor

Anexo: enlaces y verificación

Enlaces

- Pipeline y resultados: github.com/chris2009/portal-gamarrino-AI (privado).
- Incluye pipeline/ (baselines, kappa) y Muestra_378_Evaluacion/ (muestra de 378, modelo v0, Model Card).
- Datasheet del dataset: Entregable E4 (auditoría de datos).

Lo que no aplica

Búsqueda por imagen: No aplica, porque el informe preliminar ya la declaró fuera de alcance del v0 (backlog Capstone II).

Fine-tuning de un modelo propio: No aplica, porque el enfoque es RAG con embeddings pre-entrenados, no entrenamiento desde cero.

Lista de verificación antes de entregar

✓	Verificación	Evidencia P4
✓	La métrica principal se conecta con el KPI	2.4
✓	Los datos de prueba no se usaron para entrenar/ajustar	2.5
✓	Hay al menos dos baselines en la tabla	2.3 · 4.2
✓	Cada número tiene su rango	2.6
✓	Hay al menos 2 segmentos analizados	2.7
✓	La Model Card tiene sus 8 cajas llenas o 'No aplica, porque...'	5.3
✓	Los 3 riesgos tienen señal de alerta con fecha	5.4
✓	Se borraron todas las pistas en gris	—