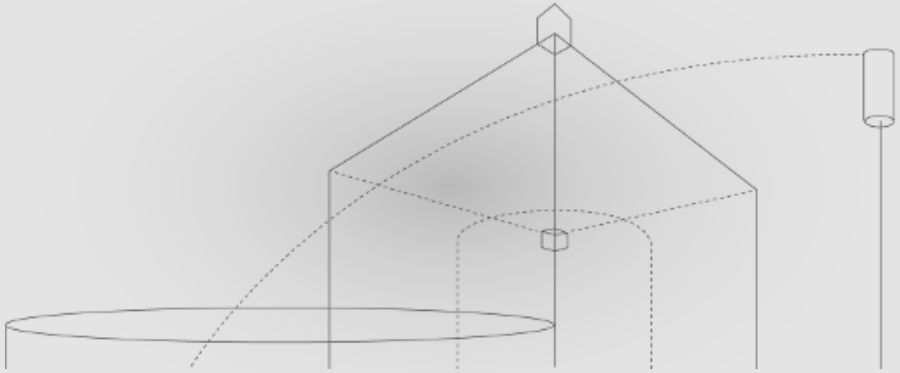
UTEC Posgrado

CAPSTONE PROJECT I · E5

Evaluación del modelo: plan, baseline, Model Card y riesgos



Equipo N.º 7 · Proyecto: Portal Gamarrino AI

Integrantes: Christian Cajusol, Hugo Ángeles, Francisco Meza, Jhomar Yurivilca ·

UTEC Posgrado

Cómo usar esta plantilla

Estructura común para todos los equipos; el contenido, las métricas y los métodos los eligen y justifican ustedes

1 **Plan de evaluación**
Las 6 preguntas del taller de la Semana 6 · *Evidencias 2.4 y 2.5 del P4*

2 **Baseline contra modelo v0**
Tabla comparativa con rangos y dónde falla el modelo · *Evidencias 2.3, 2.6, 2.7 y 4.2*

3 **Model Card v0**
Qué es el modelo, para qué sirve y para qué no · *Evidencia 5.3*

4 **Registro de 3 riesgos**
El registro del pre-mortem, completo · *Evidencia 5.4*

Reglas

- Cada caja trae pistas en gris: una para ML clásico y otra para LLM o agente. Usen la que corresponda y bórrenlas antes de entregar.
- Si algo no aplica a su proyecto, escriban «No aplica, porque…» en una línea. No fuercen contenido.
- Los números se reportan con su rango, no solos.
- Entrega por Canvas: este archivo en PDF más el enlace al notebook o repositorio.

Plan de evaluación (1/2)

1 · Problema de Agente

- Recuperación semántica + ranking top-3 (no es clasificación ni generación pura). El LLM solo redactaría la explicación breve de cada coincidencia; no decide qué tiendas se muestran.
- Unidad: consulta del usuario × catálogo de tiendas activas.
- Momento: al enviar la consulta en el asistente web móvil, antes de salir de casa (81,4%) o durante el viaje.
- Horizonte: inmediato, una sola interacción.
- Contexto: texto libre + memoria de sesión + catálogo activo (rag_text).

2 · Métrica ↔ KPI

- Métrica principal: Hit Rate@3, meta pre-registrada ≥70%.
- KPI de impacto: Tasa de recomendación útil ≥70% (informe preliminar).
- Contrapeso: latencia promedio ≤6s, p95 ≤10-12s.
- Compuesta (LLM/agente): calidad por etiquetado humano (κ); LLM juez intentado y descartado (κ=0,515, no validó); costo <$0,01 USD por esta prueba; latencia por medir (sin prototipo desplegado aún).

3 · Baselines

1. No hacer nada: 3 tiendas al azar.
2. Lo que se hace hoy: filtro por categoría (como Gamarra.com.pe / Mi Gamarra), sin NLP.
3. Modelo simple: TF-IDF/léxico sobre rag_text.
4. Modelo v0: embeddings text-embedding-3-small + similitud de coseno (ChromaDB pendiente para escalar).

Plan de evaluación (2/2)

4 · Con qué datos se prueba

- Catálogo: 438 de 1.853 tiendas (consolidado operativo).
- Consultas: muestra sistemática con arranque al azar (semilla 42) de 378 (280 textos distintos, ponderados por frecuencia real), tomadas de 4.000 consultas reales en mano (de 21.186 históricas).
- Ninguna consulta de prueba se usó para ajustar el modelo. Es una muestra piloto, no el universo completo.

5 · Un rango y dónde falla

- Rango: IC 95% por bootstrap (1.000 remuestreos) sobre las 378 consultas ponderadas.
- 3 segmentos (ver Sección 2): específica de una prenda (240 casos ponderados), ambigua o compuesta (113), con marca/talla/precio explícito (25).

6 · Criterio de decisión

- Si el Hit Rate@3 de modelo v0 no supera a los baselines por más que el rango (intervalos se cruzan) → revisar embeddings/ranking antes del 21-nov.
- Resultado real: SÍ superó, intervalos no se cruzan.
- Si el costo o la latencia real del prototipo supera 6s prom. / 10-12s p95 → simplificar pipeline o cambiar proveedor.

Baseline contra modelo v0

Una fila por opción. La métrica principal es la misma del plan, medida en el conjunto de prueba

Opción	Métrica principal: Hit Rate@3 (con rango)	Métrica de contrapeso: Latencia	Costo y latencia por caso*	N.º de casos de prueba
No hacer nada	23,0% [18,8-27,5]	—	$0	378 (280 dist.)
Lo que se hace hoy	46,8% [41,8-51,6]	Por medir	$0 / <50ms cómputo	378 (280 dist.)
Modelo simple	52,9% [48,2-57,7]	Por medir	$0 / <50ms cómputo	378 (280 dist.)

Lectura en tres líneas

De 46,8% con lo que se hace hoy (filtro por categoría) a 66,9% con el modelo v0 (ponderado, IC95% 61,9-71,4%). La diferencia es mayor que el rango de ambos — los intervalos no se cruzan, es una mejora real, no ruido.

Conclusión: se justifica construir el prototipo v0 con embeddings en vez de quedarse con el filtro simple.

** Obligatorio para LLM o agente; opcional para ML clásico.*

Dónde falla el modelo v0

Error por segmento: dónde funciona peor y por qué creen que pasa

Segmento	N.º de casos	Métrica principal	Diferencia frente al total	Por qué creemos que pasa
Total	378 (280)	66,9%	—	—
Específica (una prenda)	240 (ponder.)	79,6%	+12,7 pp	Nombre de prenda claro → el embedding encuentra match directo
Ambigua o compuesta	113 (ponder.)	50,4%	-16,5 pp	Sin prenda o estilo/tendencia sin etiqueta en catálogo (yk2, años 2000, 'de pinterest')
Con marca, talla o precio	25 (ponder.)	20,0%	-46,9 pp	Embeddings no filtran atributos estructurados (talla, precio, réplica)

Qué harán con esto antes del 21 de noviembre

Declaramos el segmento de marca/talla/precio como limitación conocida del v0 (motor semántico, no estructurado) y diseñamos un filtro híbrido (metadata + embeddings) para el prototipo del 21-nov. El segmento ambiguo queda documentado en el Model Card; no se fuerza su corrección antes de la entrega.

Model Card v0 (1/2)

Versión reducida de Mitchell et al. (2019). Una página en total, repartida en dos láminas

Qué es

Motor de recuperación semántica: embeddings text-embedding-3-small (OpenAI) sobre el catálogo (rag_text: categoría, subcategoría, tags, descripción, ubicación) + similitud de coseno para el top-3. No es un LLM generativo decidiendo — el LLM solo redactaría la explicación breve (pendiente de implementar). Versión v0, piloto.

Uso previsto

Comprador individual en Gamarra, en el asistente web móvil, para decidir qué tiendas visitar — antes de salir de casa o durante el recorrido. Responde consultas en lenguaje natural con un top-3 de tiendas del directorio.

Uso no previsto

No garantiza stock, talla o precio en tiempo real. No procesa búsqueda por imagen. No debe usarse para validar autenticidad/legalidad de productos. No es apto para consultas con restricciones estrictas de talla/marca/precio.

Datos

Catálogo de 438 tiendas de Portal Gamarrino (de 1.853 totales; ver datasheet E4). Prueba: muestra sistemática de 378 (280 distintas) de 4.000 consultas reales en mano (de 21.186 históricas), semilla 42.

Model Card v0 (2/2)

Resultados

- Hit Rate@3 = 66,9% [61,9-71,4%] (ponderado, 378 consultas), frente a 52,9% del léxico y 46,8% del filtro por categoría — mejora real, intervalos no se cruzan.
- Segmento más débil: marca/talla/precio explícito (20,0%, -46,9pp).

Cómo se evaluó

Juicios binarios Sí/No etiquetados por los 4 integrantes, doble ciego + desempate con reglas escritas. LLM juez (Claude) intentado primero: κ=0,515, no validó. Humano-humano: κ≈0,6 en consultas generales (3 réplicas independientes); κ=0,86-0,88 en los pares nuevos propuestos por modelo v0.

Limitaciones

No filtra talla/precio/disponibilidad real (HR@3 cae a 20% ahí). El acuerdo humano sobre 'relevante' tiene un techo real de κ≈0,6 en consultas ambiguas de estilo (yk2, años 2000, 'de pinterest') — el catálogo no tiene esas etiquetas. Evaluado sobre 438/1.853 tiendas y 378/21.186 consultas (piloto, no universo completo). Costo y latencia del prototipo real aún no medidos (sin despliegue).

Consideraciones éticas

No se procesan datos personales de compradores (solo texto de consulta). Catálogo sin datos de contacto expuestos fuera de lo autorizado (H3, uso académico, firmado 6-oct-2026). Riesgo: consultas piden productos 'réplica' — el sistema no debe recomendar tiendas como fuente de falsificaciones (ver riesgo 3). Sesgo potencial: el ranking puede favorecer tiendas con fichas más completas — pendiente de monitoreo.

Registro de los 3 riesgos principales

El registro del pre-mortem, completo. Categorías: datos · modelo · adopción · ética o regulación

#	Riesgo	Categoría	Prob.	Impacto	Mitigación	Señal de alerta	Responsable
1	El acuerdo humano sobre relevancia tiene un techo real de κ≈0,6 en consultas ambiguas de estilo/tendencia	Datos	Alta	Medio	Declarar la limitación en el Model Card; para Capstone II, enriquecer el catálogo con etiquetas de estilo y repetir el etiquetado con guía más detallada	Kappa de una nueva ronda de etiquetado por debajo de 0,70 al 21 de noviembre	Equipo completo
2	Los embeddings no filtran atributos estructurados (talla, precio, marca) — HR@3 cae a 20% en ese segmento, el más débil de los tres	Modelo	Alta	Alto	Diseñar un filtro híbrido (metadata estructurada + embeddings) para el prototipo del 21-nov; mientras tanto, declarar la limitación	Más del 30% de las quejas de usuarios de prueba son por talla/precio no filtrado	Equipo técnico
3	Consultas reales piden productos 'réplica' (ej. 'polos réplica a1') — recomendar tiendas sin verificar puede facilitar la venta de falsificaciones	Ética o regulación	Media	Alto	No marcar como relevante ninguna tienda en consultas de réplica (regla ya aplicada en el etiquetado); consultar con el asesor si el prototipo debe rechazar este tipo de consulta	Consultas de réplica/marca no autorizada en más del 5% de una muestra ampliada	Francisco Meza / asesor

Anexo: enlaces y verificación

Enlaces

- Pipeline y resultados: Entregables/Entregable 29-10/pipeline/ y Entregables/Muestra_378_Evaluacion/ (repositorio local del equipo).
- Datasheet del dataset: Entregable E4 (auditoría de datos).
- [ ] Repositorio en línea (GitHub) pendiente de crear antes de enviar — hoy el pipeline vive solo en Drive/disco local.

Lo que no aplica

Búsqueda por imagen: No aplica, porque el informe preliminar ya la declaró fuera de alcance del v0 (backlog Capstone II).
Fine-tuning de un modelo propio: No aplica, porque el enfoque es RAG con embeddings pre-entrenados, no entrenamiento desde cero.

Lista de verificación antes de entregar

✓	Verificación	Evidencia P4
✓	La métrica principal se conecta con el KPI	2.4
✓	Los datos de prueba no se usaron para entrenar/ajustar	2.5
✓	Hay al menos dos baselines en la tabla	2.3 · 4.2
✓	Cada número tiene su rango	2.6
✓	Hay al menos 2 segmentos analizados	2.7
✓	La Model Card tiene sus 8 cajas llenas o 'No aplica, porque...'	5.3
✓	Los 3 riesgos tienen señal de alerta con fecha	5.4
✓	Se borraron todas las pistas en gris	—